

MARIA VITÓRIA DOS SANTOS MELATO

**APLICAÇÃO DE TÉCNICAS DE APRENDIZADO DE MÁQUINA NA PREDIÇÃO DE
SATISFAÇÃO DO CLIENTE PARA E-COMMERCE**

Trabalho de Conclusão de Curso apresentado ao Instituto Federal de Educação Ciência e Tecnologia do Sudeste de Minas Gerais, Campus Muriaé, como parte das exigências do curso Superior em Tecnologia da Gestão de Tecnologia da Informação, para a obtenção do título de Tecnólogo em Gestão da Tecnologia da Informação.

Orientador(a): Prof. Dr. Gustavo Willam Pereira

MURIAÉ
MINAS GERAIS - BRASIL
2024

MARIA VITÓRIA DOS SANTOS MELATO

**APLICAÇÃO DE TÉCNICAS DE APRENDIZADO DE MÁQUINA NA PREDIÇÃO DE
SATISFAÇÃO DO CLIENTE PARA E-COMMERCE**

Trabalho de Conclusão de Curso apresentado ao Instituto Federal de Educação Ciência e Tecnologia do Sudeste de Minas Gerais, Campus Muriaé, como parte das exigências do curso Superior em Tecnologia da Gestão de Tecnologia da Informação, para a obtenção do título de Tecnólogo em Gestão da Tecnologia da Informação.

Orientador(a): Prof. Dr. Gustavo Willam Pereira

MURIAÉ
MINAS GERAIS - BRASIL
2024

MARIA VITÓRIA DOS SANTOS MELATO

**APLICAÇÃO DE TÉCNICAS DE APRENDIZADO DE MÁQUINA NA PREDIÇÃO DE
SATISFAÇÃO DO CLIENTE PARA E-COMMERCE**

Trabalho de Conclusão de Curso apresentado ao Instituto Federal de Educação Ciência e Tecnologia do Sudeste de Minas Gerais, Câmpus Muriaé, como parte das exigências do curso Superior em Tecnologia da Gestão da Tecnologia da Informação, para a obtenção do título de Tecnólogo em Gestão da Tecnologia da Informação.

APROVADA:

Prof. Nome do Professor 3

Nome do Membro da Banca

Nome do Membro da Banca

Dedico este trabalho à memória do meu pai, que partiu antes de ver sua filha se formar na faculdade, mas cuja presença sinto em cada conquista. Pai, se você estivesse aqui, sei que, mesmo cansado, estaria todos os dias na porta da faculdade, esperando para me levar de volta para casa, com a paciência de quem sempre soube o quanto esse caminho significava. Sua ausência é uma dor constante, mas também uma força que me impulsiona. Esta conquista é sua também, pois é o seu amor que me carrega, e sempre carregará, por todos os meus dias.

AGRADECIMENTOS

Primeiramente, expresso minha mais profunda gratidão a Deus, fonte de toda sabedoria, força e amor, que esteve ao meu lado a cada passo desta jornada. Sua presença constante foi o alicerce que me sustentou, especialmente no último ano de graduação. A Ele, dedico este momento de conquista, pois foi Seu apoio incondicional que me guiou, me fortaleceu nos momentos de fragilidade e me ajudou a superar cada desafio. Sou eternamente grata pela Sua provisão, que se fez presente em cada momento desta trajetória.

A minha gratidão se estende à família Melato, que se tornou meu porto seguro ao longo deste ano tão desafiador. Com generosidade, amor e acolhimento, me ensinaram a verdadeira força da família, especialmente nas adversidades. Sou profundamente grata por cada gesto de carinho, por cada palavra de incentivo e por sempre estarem ao meu lado. Vocês fizeram toda a diferença em minha vida.

Minha gratidão também é imensa ao meu pai, que, infelizmente, faleceu durante a minha jornada acadêmica. Sua partida foi uma das provas mais difíceis que enfrentei, mas seu legado, sua força e seu amor seguem vivos em meu coração. Mesmo não estando fisicamente ao meu lado neste momento, senti sua presença e inspiração me impulsionando, principalmente nos dias de maior dificuldade.

Às minhas amigadas, em especial ao Antônio e à Gabriely, minha eterna gratidão. Vocês foram a minha força nos momentos difíceis, o apoio constante que me deu coragem para seguir, e as pessoas que celebraram minhas conquistas ao meu lado. Sem o apoio de vocês, minha trajetória acadêmica e pessoal teria sido muito mais desafiadora.

Agradeço ao IF Sudeste MG - Campus Muriaé, que me proporcionou a oportunidade de realizar esta graduação e me ofereceu os meios para alcançar este sonho. Minha gratidão também se estende aos professores que compartilharam seu conhecimento e contribuíram para o meu crescimento. Um agradecimento especial ao meu orientador, Prof. Dr. Gustavo Willam, que não apenas me orientou, mas também foi o responsável por despertar em mim a paixão pela ciência de dados, que se tornou o alicerce deste trabalho.

Aos que, de alguma forma, fizeram parte dessa jornada tão especial, meu sincero agradecimento. Vocês não são apenas parte da minha história, mas vivem em meu coração, e levarei cada um de vocês comigo em minha jornada.

Por fim, agradeço a mim mesma. Agradeço por ter permanecido firme, mesmo diante das dificuldades. Por ter persistido quando os dias eram difíceis, quando a saudade apertava e as incertezas me desafiavam. Agradeço por não ter desistido de sonhar, por ter tido a coragem de continuar a construir a minha nova vida. Esta conquista é fruto da minha perseverança, e por isso, me orgulho da força que encontrei dentro de mim para chegar até aqui.

Consagre ao Senhor tudo o que você faz,
e os seus planos serão bem-sucedidos.
(Bíblia Sagrada, Provérbios 16, 3)

em

RESUMO

Este estudo teve como objetivo prever a satisfação dos clientes da Olist, uma das maiores plataformas de e-commerce do Brasil, utilizando aprendizado de máquina. A satisfação do cliente é um diferencial competitivo crucial no e-commerce, sendo influenciada por fatores como qualidade do produto, logística e atendimento. Poucas pesquisas combinaram aprendizado de máquina e análise de linguagem natural (NLP) para prever a satisfação em plataformas de grande escala como a Olist, o que justifica a realização deste estudo.

A metodologia adotada envolveu análise exploratória de dados, processamento de linguagem natural (NLP) e aprendizado de máquina. Foram analisados dados relacionados a pedidos, produtos, clientes e avaliações, com o objetivo de identificar padrões, como a relação entre o tempo de entrega e a satisfação do cliente. O processamento de linguagem natural foi utilizado para extrair sentimentos dos comentários dos clientes, enquanto modelos de aprendizado de máquina foram treinados com variáveis como tempo de entrega, avaliação do produto e sentimentos identificados.

Os resultados obtidos demonstraram alta precisão, com métricas como F1-Score e AUC-ROC superiores a 90%, e indicaram que atrasos na entrega estão fortemente correlacionados a avaliações negativas. Esse achado evidencia a importância da logística para a satisfação do cliente e pode servir como base para aprimoramento das operações da Olist.

Este estudo abre possibilidades para futuros projetos, especialmente no desenvolvimento de um sistema de recomendação personalizado, que poderia sugerir produtos com base no histórico e nas preferências dos clientes, otimizando a experiência de compra e aumentando a taxa de conversão. Além disso, a aplicação de técnicas de aprendizado profundo (deep learning) poderia aprimorar ainda mais a análise de sentimentos, capturando nuances mais complexas nos comentários e permitindo uma compreensão mais profunda das necessidades dos consumidores.

A contribuição deste trabalho para a Olist e para o setor de e-commerce é significativa. A Olist pode utilizar os resultados para melhorar sua logística, personalizar as estratégias de marketing e oferecer uma experiência de compra mais satisfatória, resultando em maior fidelização e rentabilidade. Além disso, este estudo destaca o potencial das ferramentas de análise de dados, como aprendizado de máquina e NLP, para transformar grandes volumes de dados em insights acionáveis, beneficiando tanto grandes plataformas de e-commerce quanto empresas em geral que buscam melhorar a experiência do cliente. A continuidade da pesquisa, com a implementação de sistemas de recomendação avançados e o uso de tecnologias de aprendizado profundo, pode revolucionar a gestão da experiência do cliente, promovendo uma personalização ainda mais precisa e eficiente no e-commerce.

Palavras-chave: E-commerce. Aprendizado de Máquina. Satisfação do cliente. Análise de dados. NLP. Predição.

ABSTRACT

This study aimed to predict customer satisfaction on Olist, one of the largest e-commerce platforms in Brazil, using machine learning. Customer satisfaction is a crucial competitive differentiator in e-commerce, influenced by factors such as product quality, logistics, and customer service. Few studies have combined machine learning and natural language processing (NLP) to predict satisfaction on large-scale platforms like Olist, which justifies the need for this research.

The methodology involved exploratory data analysis, natural language processing (NLP), and machine learning. Data related to orders, products, customers, and reviews were analyzed to identify patterns, such as the relationship between delivery time and customer satisfaction. NLP was used to extract sentiments from customer comments, while machine learning models were trained with variables like delivery time, product rating, and identified sentiments.

The results demonstrated high accuracy, with metrics such as F1-Score and AUC-ROC exceeding 90%, and indicated that delivery delays are strongly correlated with negative reviews. This finding highlights the importance of logistics for customer satisfaction and can serve as a basis for improving Olist's operations.

This study opens up possibilities for future projects, particularly the development of a personalized recommendation system that could suggest products based on customer history and preferences, optimizing the shopping experience and increasing conversion rates. Additionally, the application of deep learning techniques could further enhance sentiment analysis, capturing more complex nuances in comments and providing a deeper understanding of consumer needs.

The contribution of this work to Olist and the e-commerce sector is significant. Olist can use the results to improve logistics, personalize marketing strategies, and provide a more satisfying shopping experience, leading to greater customer loyalty and profitability. Furthermore, this study highlights the potential of data analysis tools, such as machine learning and NLP, to transform large volumes of data into actionable insights, benefiting both large e-commerce platforms and companies seeking to improve customer experience. The continuation of this research, with the implementation of advanced recommendation systems and the use of deep learning technologies, could revolutionize customer experience management, promoting more accurate and efficient personalization in e-commerce.

Key-words: E-commerce. Machine Learning. Customer Satisfaction. Data Analysis. NLP. Prediction.

LISTA DE ILUSTRAÇÕES

SUMÁRIO

1	INTRODUÇÃO	10
1.1	APRESENTAÇÃO DA EMPRESA E DOS DADOS	10
1.2	DESCRIÇÃO DO PROBLEMA	10
1.3	OBJETIVOS	11
1.3.1	OBJETIVO GERAL	11
1.3.2	OBJETIVO ESPECÍFICOS	11
1.4	JUSTIFICATIVA	11
1.5	ORGANIZAÇÃO DO TEXTO	12
2	REVISÃO BIBLIOGRÁFICA	13
2.1	ANÁLISE EXPLORATÓRIA DE DADOS	13
2.2	MACHINE LEARNING	13
2.2.1	<i>K-NEAREST NEIGHBORS (KNN)</i>	14
2.2.2	<i>REGRESSÃO LOGÍSTICA</i>	14
2.2.3	<i>ÁRVORE DE DECISÃO</i>	14
2.2.4	<i>RANDOM FOREST</i>	14
2.2.5	<i>GRADIENT BOOSTING</i>	15
2.2.6	<i>SUPORT VECTOR MACHINE - SVM</i>	16
2.2.6.1	<i>SUPORT VECTOR CLASSIFIER - SVC</i>	16
2.3	DESBALANCEAMENTO DE CLASSES	17
2.3.1	<i>UNDERSAMPLING</i>	17
2.3.2	<i>OVERSAMPLING</i>	17
2.4	PROCESSAMENTO DE LINGUAGEM NATURAL	18
2.4.1	<i>BIBLIOTECA LeIA PARA ANÁLISE DE SENTIMENTOS</i>	18
2.4.2	<i>VETORIZADOR TF-IDF</i>	18
2.5	MÉTRICAS DE AVALIAÇÃO	18
2.5.1	<i>ACURÁCIA</i>	18
2.5.2	<i>MATRIZ DE CONFUSÃO</i>	19
2.5.3	<i>AUC-ROC</i>	19
2.5.4	<i>F1-SCORE</i>	20

3	METODOLOGIA	21
3.1	ANÁLISE EXPLORATÓRIA DE DADOS	21
3.2	MODELAGEM PREDITIVA COM MACHINE LEARNING	21
3.3	DEPLOY COM STREAMLIT	22
3.4	TECNOLOGIAS UTILIZADAS	22
3.5	AMBIENTE DE DESENVOLVIMENTO	23
4	RESULTADOS	24
4.1	ANÁLISE EXPLORATÓRIA DE DADOS	24
4.1.1	<i>ANÁLISE DOS PEDIDOS</i>	24
4.1.2	<i>ANÁLISE DOS PREÇOS</i>	29
4.1.3	<i>ANÁLISE DAS AVALIAÇÕES</i>	31
4.1.4	<i>MÉTRICAS E KPIs</i>	34
4.2	ANÁLISE DA SATISFAÇÃO DOS CLIENTES	37
5	CONCLUSÃO	44
	REFERÊNCIAS	45

1 INTRODUÇÃO

Nos últimos anos, o campo da Ciência de Dados tem experimentado uma evolução acelerada, impulsionada por avanços significativos em aprendizado de máquina, análise preditiva e exploração de dados. Essas inovações têm transformado setores como o e-commerce, permitindo às empresas utilizar dados para melhorar suas operações, identificar padrões de comportamento e tomar decisões mais assertivas. O e-commerce, em particular, gera uma vasta quantidade de informações valiosas que podem ser analisadas para otimizar processos logísticos, estratégias de marketing e a experiência do cliente.

A análise de dados desempenha um papel crucial nesse cenário, pois possibilita não apenas entender o comportamento dos consumidores, mas também identificar oportunidades de melhoria em toda a cadeia de valor. Este trabalho combina a análise exploratória de dados para obtenção de insights estratégicos com o desenvolvimento de um modelo preditivo voltado à satisfação do cliente, oferecendo soluções que podem contribuir para a tomada de decisões na empresa estudada.

1.1 APRESENTAÇÃO DA EMPRESA E DOS DADOS

A Olist é a maior loja de departamentos em marketplaces no Brasil, conectando pequenos comerciantes a diversos canais de venda. A empresa gerencia um grande volume de dados relacionados a transações, incluindo informações sobre status dos pedidos, preços, pagamentos, desempenho do frete, localização dos clientes, atributos dos produtos e avaliações pós-compra.

O conjunto de dados utilizado neste estudo foi disponibilizado pela Olist na plataforma Kaggle. Ele contém informações anonimizadas de transações realizadas entre setembro de 2016 e outubro de 2018, totalizando 99.441 compras, 3.095 vendedores e 96.096 consumidores.

1.2 DESCRIÇÃO DO PROBLEMA

A satisfação do cliente é um fator crítico para o sucesso de empresas de e-commerce como a Olist. Compreender as necessidades dos consumidores e melhorar continuamente os serviços oferecidos são desafios estratégicos para a empresa. No entanto, a grande quantidade de dados gerados diariamente pode dificultar a identificação de padrões e a priorização de ações.

Neste contexto, este trabalho teve como objetivos principais:

- Realizar uma análise exploratória de dados para identificar padrões e insights que possam auxiliar a Olist na tomada de decisões estratégicas.
- Desenvolver um modelo preditivo para identificar fatores que influenciam a satisfação dos clientes, utilizando informações como prazo de entrega, valor do frete, categoria do produto, entre outras.

A combinação dessas abordagens permite não apenas entender o estado atual dos processos operacionais, mas também oferecer previsões e recomendações para melhorar a experiência do consumidor e a eficiência das operações logísticas.

1.3 OBJETIVOS

1.3.1 OBJETIVO GERAL

Desenvolver uma abordagem analítica que integre análise exploratória de dados e Machine Learning para identificar fatores que influenciam a satisfação dos clientes da Olist e criar um modelo preditivo capaz de prever a satisfação do cliente com base nos dados de compra, a fim de apoiar decisões estratégicas da empresa e melhorar a experiência do consumidor.

1.3.2 OBJETIVO ESPECÍFICOS

- Analisar padrões de comportamento de compra e desempenho de vendas na Olist, incluindo variações por região, estado, categoria de produto e tipo de pagamento, para identificar tendências estratégicas.
- Explorar a relação entre métricas de entrega, como tempo e custo de frete, e a satisfação dos clientes, considerando variações regionais e estaduais.
- Investigar os fatores que influenciam a pontuação de avaliações dos clientes, como categoria de produto, tipo de pagamento e tempo de entrega, para entender as principais causas de satisfação e insatisfação.
- Desenvolver um modelo preditivo para classificar a satisfação do cliente, utilizando dados de compra e avaliação para prever a probabilidade de um cliente estar satisfeito ou insatisfeito.

1.4 JUSTIFICATIVA

A análise da satisfação do cliente no e-commerce justifica-se pela crescente necessidade de empresas entenderem melhor os fatores que influenciam a experiência de compra e a satisfação dos consumidores. No contexto do e-commerce, em especial no caso do Olist, a ausência de feedbacks e avaliações completas dificulta a compreensão das preferências e das críticas dos clientes. Com base nas diversas análises realizadas, como a variação do número de pedidos por região, o comportamento de pagamento, a relação entre tempo de entrega e avaliações, e a distribuição geográfica dos consumidores, é possível identificar padrões e insights que ajudam a prever a satisfação do cliente. O desenvolvimento de um modelo de predição de satisfação com base em dados de avaliações e outras métricas permitirá às empresas otimizar suas estratégias de marketing, melhorar a experiência do cliente e agir de forma mais proativa em relação a produtos que possam precisar de ajustes.

1.5 ORGANIZAÇÃO DO TEXTO

O trabalho está estruturado da seguinte forma:

1. **Introdução:** apresenta o contexto do trabalho, incluindo os objetivos gerais e específicos da pesquisa, seguidos pela justificativa para a realização do estudo e pela organização do texto, que oferece uma visão geral sobre a estrutura do trabalho.
2. **Revisão Bibliográfica:** serão explorados os conceitos fundamentais relacionados ao aprendizado de máquina, os modelos utilizados para análise de dados e as técnicas aplicadas para a construção de modelos preditivos, além de uma discussão sobre trabalhos anteriores que abordaram temas semelhantes. Este capítulo visa fornecer o embasamento teórico necessário para compreender as escolhas metodológicas e as abordagens adotadas ao longo do estudo.
3. **Metodologia:** descreve as tecnologias e ferramentas utilizadas no desenvolvimento do modelo preditivo, bem como o ambiente de desenvolvimento adotado para a implementação do sistema. Além disso, serão detalhados os processos seguidos para a coleta, processamento e análise dos dados, incluindo as etapas para a construção do modelo de previsão de satisfação do cliente.
4. **Resultados:** apresenta os resultados obtidos a partir da implementação do modelo de aprendizado de máquina e a avaliação da precisão das previsões geradas. Serão discutidos também os insights extraídos das análises e como esses podem contribuir para a melhoria da experiência do cliente no e-commerce.
5. **Considerações Finais:** traz uma síntese das conclusões do estudo, apontando as contribuições do trabalho, as limitações enfrentadas e as sugestões para pesquisas futuras, além de refletir sobre o impacto das previsões de satisfação do cliente para a gestão de e-commerce.

2 REVISÃO BIBLIOGRÁFICA

2.1 ANÁLISE EXPLORATÓRIA DE DADOS


Conforme descrito pela EBAC (2023), a Análise Exploratória de Dados (AED), ou *Exploratory Data Analysis* (EDA), é uma abordagem essencial no trabalho de cientistas de dados. Ela oferece uma visão panorâmica dos dados, permitindo identificar padrões, explorar variáveis e extrair informações valiosas. Esse processo é crucial para a construção de modelos de *Machine Learning*, pois fornece os insights iniciais necessários para alimentar as etapas subsequentes da análise.

Além disso, a AED desempenha um papel crucial ao simplificar a complexidade dos dados, transformando-os em conhecimento útil. Sua aplicação é amplamente reconhecida como essencial para lidar com grandes volumes de informações e garantir a qualidade dos resultados obtidos durante o processo de análise.

2.2 MACHINE LEARNING

De acordo com a AWS (2023), "Machine Learning é a ciência do desenvolvimento de algoritmos e modelos estatísticos que os sistemas de computador usam para realizar tarefas sem instruções explícitas, confiando em padrões e inferências". Através desse processo, sistemas podem identificar padrões em grandes volumes de dados para prever resultados de maneira precisa e eficiente.

Figura 1: Fluxo de trabalho comum no Machine Learning



Fonte: Matt Harrison (2019)

2.2.1 K-NEAREST NEIGHBORS (KNN)

Conforme descrito pela IBM (2023), o algoritmo k-Nearest Neighbors (kNN) é um classificador supervisionado e não paramétrico amplamente utilizado em aprendizado de máquina, especialmente para problemas de classificação. Ele atribui rótulos de classe com base na proximidade dos pontos e em uma votação entre os vizinhos mais próximos. Embora frequentemente chamado de "votação majoritária", em problemas com múltiplas classes o kNN pode utilizar a "votação por pluralidade", onde a classe mais representada entre os vizinhos é atribuída, mesmo sem alcançar mais de 50% dos votos.

2.2.2 REGRESSÃO LOGÍSTICA

A regressão logística é uma técnica de análise de dados que usa matemática para encontrar as relações entre dois fatores de dados. Em seguida, essa relação é usada para prever o valor de um desses fatores com base no outro. A previsão geralmente tem um número finito de resultados, como sim ou não. (AWS, 2024)

Apesar de ser relativamente simples, a regressão logística pode se beneficiar de ajustes com regularização (como L1 ou L2) para evitar overfitting, especialmente quando o conjunto de dados é grande e contém muitas variáveis. Isso torna o modelo bastante flexível e aplicável a diferentes cenários, como a predição da satisfação do cliente com base em múltiplos fatores.

2.2.3 ÁRVORE DE DECISÃO

Os algoritmos baseados em árvores de decisão são amplamente aplicados em diversas áreas, como classificação, regressão e seleção de atributos. A ideia central é dividir os dados recursivamente em subconjuntos com base em atributos, criando uma estrutura de árvore, onde cada nó representa uma decisão baseada em um atributo específico. A escolha do melhor atributo para a divisão é feita com base em critérios como ganho de informação, razão de ganho e índice de Gini. Elas são eficientes ao lidar com dados categóricos e numéricos, eliminando a necessidade de pré-processamento de dados, o que as torna mais versáteis e eficazes em uma ampla gama de aplicações (IEEE, 2024).

2.2.4 RANDOM FOREST

Random Forest é um método de aprendizado de conjunto que combina várias árvores de decisão para formar um modelo mais robusto e preciso. Nesse sentido, sua ideia central é construir múltiplas árvores de decisão durante o treinamento e, para a predição, cada árvore votar no resultado final, seja ele uma classe (para problemas de classificação) ou um valor numérico (para problemas de regressão) (DataGeeks, 2024).


2.2.5 GRADIENT BOOSTING

O Gradient Boosting é um algoritmo de aprendizado de máquina amplamente utilizado para tarefas de classificação e regressão. Ele pertence à família dos métodos de ensemble, ou seja, combina várias previsões de modelos simples para criar um modelo mais robusto e preciso. O diferencial do Gradient Boosting é seu processo iterativo, no qual ele aprimora progressivamente o modelo inicial ao focar nas previsões erradas do modelo anterior. Isso permite que o modelo final seja altamente eficaz, mesmo com dados complexos. (Belyadi, H., Haghighat, A. 2021)

O Gradient Boosting funciona por meio de um processo iterativo de aprimoramento de modelos fracos, que são combinados para formar um modelo mais robusto. Inicialmente, começa-se com um modelo simples, muitas vezes uma previsão constante ou uma árvore de decisão superficial. O próximo passo é calcular os resíduos, ou seja, a diferença entre os valores reais e as previsões feitas pelo modelo atual. Em seguida, um novo aprendiz fraco é treinado para capturar padrões nos erros do modelo anterior.

Esse novo aprendiz é adicionado ao ensemble, com sua contribuição ajustada por meio de um parâmetro de taxa de aprendizado. Esse processo é repetido várias vezes, com cada iteração melhorando a capacidade preditiva do modelo. A cada iteração, a ênfase é colocada nos erros difíceis de prever, permitindo que o modelo se aprimore continuamente. (Medium, 2024)

Figura 2: Diagrama do Gradient Boosting




Fonte: Medium (2024)

2.2.6 SUPORT VECTOR MACHINE - SVM

O SVM é um algoritmo que busca uma linha de separação entre duas classes distintas analisando os dois pontos, um de cada grupo, mais próximos da outra classe. Isto é, o SVM escolhe a reta — também chamada de hiperplano em maiores dimensões— entre dois grupos que se distancia mais de cada um (no caso abaixo, a reta vermelha). Após descoberta essa reta, o programa conseguirá prever a qual classe pertence um novo dado ao checar de qual lado da reta ele está. (Medium, 2024)

Figura 3: Visualização da Reta Ótima (H3) no SVM



Fonte: Wikimedia Commons (2012)

2.2.6.1 SUPORT VECTOR CLASSIFIER - SVC

O Support Vector Classifier (SVC) é um algoritmo supervisionado que busca separar classes em um conjunto de dados por meio de um hiperplano que maximiza a margem entre os vetores de suporte, que são os pontos mais próximos de cada classe. Para lidar com dados não linearmente separáveis, o SVC utiliza funções kernel, como o linear, polinomial ou RBF, que mapeiam os dados para um espaço dimensional superior, permitindo uma separação mais eficaz.

Além disso, o SVC possui um parâmetro de regularização, C , que controla o equilíbrio entre minimizar erros de classificação e maximizar a margem, favorecendo a generalização do modelo. Por ser sensível à escala das variáveis, é essencial padronizar os dados antes de aplicá-lo, garantindo que todos os atributos contribuam de forma uniforme para a definição do hiperplano.

2.3 DESBALANCEAMENTO DE CLASSES

Dados desbalanceados, comuns em diversas áreas como saúde e finanças, caracterizam-se por uma distribuição desigual entre classes, o que representa um desafio significativo para problemas de classificação. Essa disparidade dificulta a detecção de padrões relevantes para classes minoritárias e pode enviesar métricas tradicionais, como a acurácia, favorecendo a classe majoritária (TurinTech, 2022).

2.3.1 UNDERSAMPLING

Undersampling é uma técnica utilizada para equilibrar as proporções entre as classes em um conjunto de dados, reduzindo o número de observações da classe majoritária. Isso pode ser feito de duas maneiras principais:


- **Random Undersampling:** Retirada aleatória de dados da classe majoritária, o que pode causar perda de informações importantes.
- **Métodos de Fusão:** Técnicas como k-NN ou NearMiss combinam observações da classe majoritária, preservando melhor a informação e reduzindo a perda de dados.

2.3.2 OVERSAMPLING

Cria novas observações para a classe minoritária, com o objetivo de equilibrar as classes. Pode ser feito de duas maneiras:

- **Random Oversampling:** Simplesmente duplica dados da classe minoritária, o que pode ser eficaz se os parâmetros da classe minoritária não variam muito.
- **SMOTE (Synthetic Minority Over-sampling Technique):** Gera observações sintéticas entre dados semelhantes, criando exemplos intermediários e tentando representar melhor a classe minoritária como um todo, em vez de apenas duplicar exemplos.

Figura 4: Undersampling e Oversampling



Fonte: TurinTech (2022)

2.4 PROCESSAMENTO DE LINGUAGEM NATURAL

O processamento de linguagem natural (NLP) é um campo da inteligência artificial que capacita os computadores a entender, gerar e manipular a linguagem humana, seja por texto ou voz. Ele é amplamente utilizado em assistentes virtuais, como Siri, Cortana e Alexa, permitindo que compreendam as perguntas dos usuários e respondam de forma natural. Além disso, o NLP é aplicado em diversas ferramentas, como pesquisa na web, tradução automática, análise de sentimentos e correção gramatical. Ele também é usado em sistemas de e-mail para sugerir respostas automáticas com base no conteúdo das mensagens (Oracle, 2024).

2.4.1 BIBLIOTECA LeIA PARA ANÁLISE DE SENTIMENTOS

LeIA (Léxico para Inferência Adaptada) é uma biblioteca de análise de sentimentos projetada especificamente para o português brasileiro, baseada em Python. Ela segue princípios semelhantes ao modelo VADER (Valence Aware Dictionary for Sentiment Reasoning), mas foi adaptada para lidar com as particularidades da língua portuguesa, incluindo expressões comuns, vocabulário e estruturas gramaticais únicas do português brasileiro. (GitHub, 2018)

2.4.2 VETORIZADOR TF-IDF

O TF-IDF (Term Frequency-Inverse Document Frequency) é uma técnica de vetorização de texto usada para medir a importância de uma palavra dentro de um conjunto de documentos. O TF calcula a frequência de um termo em um único documento, enquanto o IDF ajusta essa frequência considerando a raridade da palavra em todo o corpus. O objetivo do TF-IDF é aumentar o peso de palavras específicas e menos comuns, reduzindo a relevância de palavras frequentes como artigos e conjunções. Essa técnica é fundamental para tarefas como recuperação de informação, classificação e agrupamento de textos, sendo amplamente utilizada por mecanismos de busca como o Google. (Semantix, 2023)

2.5 MÉTRICAS DE AVALIAÇÃO


2.5.1 ACURÁCIA

Acurácia é uma métrica fundamental que mede a proporção de previsões corretas feitas por um modelo em relação ao total de instâncias. Ela é frequentemente a primeira métrica considerada para avaliar modelos de classificação, sendo simples de entender e útil quando as classes são equilibradas. No entanto, pode ser enganosa em cenários de desbalanceamento de classes, onde uma classe pode ser mais representada do que a outra, o que pode levar o modelo a uma alta acurácia, mas com um desempenho ruim na classe menos representada (Encord, 2023).

2.5.2 MATRIZ DE CONFUSÃO

A matriz de confusão é uma tabela que descreve o desempenho de um modelo de classificação, mostrando as previsões corretas e incorretas. Ela é composta por quatro componentes: True Positives (TP), False Positives (FP), True Negatives (TN), e False Negatives (FN). Esses valores ajudam a entender como o modelo está fazendo suas previsões, focando nas classificações corretas e nos erros (Analytics India Magazine, 2019).

Figura 5: Matriz de confusão




Fonte: IBM (2024)

2.5.3 AUC-ROC

A AUC-ROC mede o desempenho de modelos de classificação binária em diferentes limiares de decisão. Ela representa a área sob a curva da taxa de verdadeiros positivos em relação à taxa de falsos positivos. Quanto maior a AUC-ROC, melhor o modelo está separando as classes. Um valor de AUC-ROC de 0,5 indica desempenho aleatório, enquanto 1 indica um desempenho perfeito (Sigmoidal, 2023).

Figura 6: Curva ROC



Fonte: (Sigmoidal, 2023)

2.5.4 F1-SCORE

O F1-Score é uma métrica que equilibra a precisão e o recall, calculada como a média harmônica entre esses dois valores. Ele é útil quando se busca um equilíbrio entre alta precisão e recall, penalizando valores extremos de qualquer um dos componentes. Diferente da acurácia, que mede a correção geral das previsões, o F1-Score foca na qualidade das previsões positivas e negativas, tornando-se uma métrica mais completa para avaliar modelos de classificação (Klu AI, 2023).

Para calcular a pontuação F1, podemos usar uma matriz de confusão, que resume o desempenho preditivo de um modelo em uma tarefa de classificação binária (classes positiva e negativa). A matriz de confusão consiste em quatro componentes principais, descritos a seguir:

- **Verdadeiros Positivos (TP)**: Instâncias corretamente classificadas como positivas.
- **Verdadeiros Negativos (TN)**: Instâncias corretamente classificadas como negativas.
- **Falsos Positivos (FP)**: Instâncias incorretamente classificadas como positivas.
- **Falsos Negativos (FN)**: Instâncias incorretamente classificadas como negativas.

Com esses componentes, podemos calcular a pontuação F1 usando a seguinte fórmula:

$$F_1 = \frac{2 \cdot \text{Precisão} \cdot \text{Recall}}{\text{Precisão} + \text{Recall}}$$

onde:

$$\text{Precisão} = \frac{TP}{TP + FP}$$

$$\text{Recall} = \frac{TP}{TP + FN}$$

3 METODOLOGIA

Este trabalho visa aplicar técnicas de Machine Learning (ML) e Processamento de Linguagem Natural (NLP) para analisar e prever a satisfação dos clientes em um e-commerce, com foco em dados de pedidos, pagamentos, avaliações e logística. A metodologia segue uma abordagem estruturada, que abrange desde o pré-processamento dos dados até a construção de modelos preditivos. Abaixo, são detalhadas as etapas metodológicas adotadas para a análise da satisfação do cliente e a construção de modelos preditivos.

3.1 ANÁLISE EXPLORATÓRIA DE DADOS

A análise exploratória de dados (EDA) teve como objetivo obter insights sobre pedidos, clientes e produtos em uma plataforma de e-commerce. A análise incluiu aspectos temporais, geográficos e de comportamento de compra. Foi investigado o número de pedidos ao longo do tempo e a distribuição das vendas por região e tipo de pagamento. Também foram analisadas as categorias de produtos, a relação entre preço, frete e localização, e as avaliações dos clientes, com foco no impacto do tempo de entrega na pontuação.

A análise geográfica revelou a predominância de pedidos no estado de São Paulo e a análise dos vendedores mostrou o volume de pedidos entregues por cada um. Além disso, foram avaliados KPIs importantes como Receita Recorrente Mensal (MRR), taxa de crescimento mensal e retenção de clientes.

A metodologia proporcionou uma análise detalhada dos comportamentos de compra e do desempenho do e-commerce, identificando pontos fortes e áreas para melhoria.

3.2 MODELAGEM PREDITIVA COM MACHINE LEARNING

Após a análise exploratória dos dados e a extração de variáveis relevantes, o próximo passo foi a construção de modelos de aprendizado de máquina para classificar os sentimentos das avaliações. Inicialmente, o sentimento de cada comentário é classificado usando o *SentimentIntensityAnalyzer* do *NLTK*, que categoriza as avaliações como "Positivo", "Negativo" ou "Neutro". Essa análise é realizada por meio da aplicação de uma função que analisa a coluna de comentários limpos das avaliações.

Em seguida, uma nuvem de palavras é gerada para todo o conjunto de dados e separadamente para os sentimentos "Positivo" e "Negativo", destacando as palavras mais frequentes em cada grupo. Além disso, é realizada uma análise da distribuição de tokens em cada comentário com um histograma e a contagem das palavras mais frequentes, representada por um gráfico de barras. Também são analisados bigrams, ou pares de palavras mais comuns nas avaliações.

Para entender a distribuição dos sentimentos, um gráfico de barras é gerado, mostrando a contagem de avaliações em cada categoria de sentimento. Com base nessa análise exploratória, é possível partir para a modelagem preditiva. O conjunto de dados é dividido em conjuntos de

treinamento e teste, e o texto das avaliações é transformado em matrizes numéricas por meio do Vetorizador TF-IDF. Modelos de Machine Learning, como *DecisionTreeClassifier*, *RandomForestClassifier*, *LogisticRegression*, *GradientBoostingClassifier* e *Support Vector Classifier* são treinados para prever o sentimento das avaliações.

A avaliação dos modelos é realizada por meio de métricas como a acurácia nos conjuntos de treinamento e teste, além da análise da importância das features, que revela quais palavras contribuíram mais para a classificação. Para entender melhor o desempenho dos modelos, são apresentadas as matrizes de confusão e as curvas ROC, incluindo o cálculo da AUC (Área sob a Curva) e F1-Score, que permite avaliar a capacidade dos modelos em distinguir entre as diferentes classes de sentimentos.

Essa metodologia proporciona uma análise profunda do sentimento nas avaliações de produtos, seguido de uma previsão automática do sentimento por meio de modelos de Machine Learning, com uma avaliação detalhada da performance desses modelos.

3.3 DEPLOY COM STREAMLIT

O modelo de predição foi salvo utilizando a biblioteca joblib, garantindo sua reutilização de forma eficiente. Posteriormente, realizou-se o processo de ETL para preparar os dados para o uso na aplicação Streamlit. O arquivo principal, `app.py`, foi estruturado para integrar duas funcionalidades principais:

- **Análise Exploratória de Dados (EDA):** Inclui a exibição de gráficos interativos e resultados obtidos durante a análise exploratória, permitindo uma visualização clara e informativa dos dados processados.
- **Modelo de Predição de Satisfação:** Integra o modelo treinado, permitindo que o usuário faça previsões de satisfação com base nos dados fornecidos.

Essa abordagem facilitou a interação com os dados e resultados, tornando o deploy funcional e acessível para os usuários finais.

3.4 TECNOLOGIAS UTILIZADAS

Para o desenvolvimento deste trabalho, diversas tecnologias e bibliotecas foram empregadas, cada uma com um papel fundamental em diferentes etapas do processo:

1. **Pandas e NumPy:** Utilizadas para manipulação e análise de dados. Essas bibliotecas facilitaram o tratamento e a organização dos datasets, permitindo a realização de operações matemáticas e transformações de dados de forma eficiente.

2. **Matplotlib e Seaborn:** Essenciais para a construção de gráficos e visualizações de dados durante a etapa de Análise Exploratória (EDA). Elas possibilitaram uma melhor compreensão das características dos dados, como distribuições, correlações e padrões.
3. **Scikit-learn:** Biblioteca principal para a criação do modelo de aprendizado de máquina. Foi utilizada para treinamento, validação, ajuste de hiperparâmetros e salvamento do modelo final, além de oferecer ferramentas úteis para pré-processamento de dados.
4. **NLTK (Natural Language Toolkit):** Biblioteca central para as tarefas de Processamento de Linguagem Natural (NLP). Foi usada para limpeza, tokenização e análise textual, auxiliando na extração de padrões e informações relevantes dos dados textuais.
5. **Streamlit:** Ferramenta utilizada para criar o deploy interativo do projeto. Permitindo a construção de uma interface visual simples e funcional, Streamlit tornou possível a apresentação dos resultados da análise exploratória e a realização de previsões com o modelo treinado.

Essas tecnologias, em conjunto, possibilitaram o desenvolvimento de um fluxo integrado que vai desde o pré-processamento dos dados até a entrega de uma aplicação acessível e prática para o usuário final.

3.5 AMBIENTE DE DESENVOLVIMENTO

O desenvolvimento deste trabalho foi realizado utilizando o Jupyter Notebook como ambiente de desenvolvimento. O código foi implementado em um computador Dell G15, equipado com um processador Intel® Core™ i5-10500H @ 2.50GHz, 24GB de RAM e um SSD de 240GB. O sistema operacional utilizado foi o Windows 11 Pro, na versão 23H2.

4 RESULTADOS


Neste capítulo, serão apresentados os resultados da análise exploratória de dados (EDA) e do modelo de predição. Serão discutidas as principais descobertas da EDA, padrões identificados nos dados e a performance do modelo, destacando sua aplicabilidade e precisão. O objetivo é fornecer uma visão clara dos insights obtidos e da eficácia do modelo aplicado.

4.1 ANÁLISE EXPLORATÓRIA DE DADOS

4.1.1 ANÁLISE DOS PEDIDOS


Para analisar o comportamento do número de pedidos ao longo do tempo, foi criada uma visualização que mostra a quantidade de pedidos por dia. A análise do número de pedidos ao longo do tempo, ilustrada na Figura 7, mostrou um pico em 24 de novembro de 2017, data da Black Friday. Esse aumento reflete o impacto significativo de datas promocionais no comércio eletrônico, destacando sua relevância para o aumento de transações na plataforma.

Figura 7: Número de pedidos por dia




O gráfico apresentado na Figura 8 mostra a distribuição do número de pedidos por tipo de pagamento. A análise revelou que o cartão de crédito é o método de pagamento mais utilizado, seguido pelo boleto, que representa cerca de 25% do volume de pagamentos feitos com cartão de crédito. O vale e o cartão de débito ocupam, respectivamente, a terceira e quarta posições no ranking de pagamentos.

Figura 8: Distribuição do Número de Pedidos por Tipo de Pagamento




Para analisar a variação do número de pedidos por região, foi gerada uma visualização que mostra o número de pedidos por dia em diferentes regiões, conforme apresentado na Figura 8. A análise dos dados de 2018 revelou que a região Sudeste teve o maior número de pedidos ao longo de todo o ano, com uma proporção consistente de pedidos em relação às demais regiões. Embora o número de pedidos tenha variado ao longo do tempo, a proporção entre as regiões permaneceu praticamente a mesma. Esse comportamento sugere uma estabilidade nas preferências regionais, com a região Sudeste liderando, mas sem grandes flutuações ao longo do ano.

Figura 9: Variação do Número de Pedidos por Região ao Longo de 2018




A análise da distribuição semanal dos pedidos não entregues em 2018, ilustrada na Figura 10, revela padrões interessantes. Observa-se um pico no número de pedidos cancelados entre as semanas 4 e 9, seguido por outro aumento em torno da 30ª semana. Esses picos podem indicar sazonalidade ou fatores específicos que influenciam o comportamento dos pedidos ao longo do ano. Investigar se esses padrões se repetem em outros anos pode ajudar a identificar causas subjacentes e propor estratégias para diminuir esses eventos.

Figura 10: Distribuição Semanal dos Pedidos Não Entregues em 2018




Para investigar se o pico de cancelamentos observado em 2018 nas semanas 4 a 9 e por volta da 30ª semana era um padrão anual, foram analisados os dados de 2017. O gráfico apresentado na Figura 11 revela que não há um padrão anual semelhante ao observado em 2018. Contudo, destaca-se que, assim como em 2018, o número de pedidos cancelados é maior entre as semanas 30 e 33.

Figura 11: Distribuição Semanal dos Pedidos Não Entregues em 2017




A análise dos números de pedidos por categoria, mostrada na Figura 12, revela que as categorias com maior volume de vendas incluem cama, mesa e banho, beleza e saúde, esporte e lazer, móveis de decoração e informática e acessórios, sendo que estas representam as principais fontes de receita para a plataforma. Por outro lado, categorias como seguros e serviços e CDs e DVDs musicais apresentam um desempenho abaixo do esperado. Isso indica que a Olist pode querer reavaliar sua estratégia em relação a esses produtos, uma vez que o mercado digital tem se distanciado dessas áreas.

Figura 12: Distribuição de Pedidos por Categoria de Produto




A análise do gráfico da Figura 13 mostra que São Paulo lidera em número de pedidos, seguido por Rio de Janeiro e Minas Gerais, ambos da Região Sudeste, um importante polo de consumo e logística. Já os estados do Norte têm volumes bem menores, sugerindo desafios logísticos ou um alcance limitado do e-commerce nessa região. Isso aponta para uma oportunidade de a Olist ajustar suas estratégias para melhorar a presença e a logística no Norte.

Figura 13: Distribuição de Pedidos por Estado



O gráfico da Figura 14 mostra que não há um padrão claro de compras mais frequentes no início do mês, mas é possível notar uma queda significativa no número de pedidos a partir do 28º dia. Esse comportamento pode indicar que os consumidores reduzem suas compras conforme o mês avança, talvez devido ao esgotamento do orçamento ou outras prioridades. A Olist poderia aproveitar essa tendência para ajustar suas estratégias de vendas, oferecendo promoções no final do mês, visando impulsionar as compras nesse período.

Figura 14: Distribuição do Número de Pedidos ao Longo do Mês



A análise dos gráficos nas Figuras 15 e 16 mostra que a segunda-feira tem o maior número de pedidos, o que pode ser aproveitado com promoções nesse dia. Já a sexta-feira, embora com menos pedidos, apresenta o maior valor médio de pagamento, indicando que os consumidores gastam mais próximo ao fim da semana. Esse comportamento pode ser explorado com ofertas e descontos direcionados para aumentar o ticket médio nas sextas-feiras. O fim de semana, com menor volume de pedidos e valores, pode ser uma oportunidade para otimizar campanhas e engajar mais consumidores.

Figura 15: Número de Pedidos por Dia da Semana






Figura 16: Valor Médio de Pagamento por Dia da Semana



A análise da Figura 17 revela que as cinco cidades com o maior número de pedidos são, respectivamente, São Paulo, Rio de Janeiro, Belo Horizonte, Brasília e Curitiba. Esse padrão reflete a forte concentração de consumo nas capitais e grandes centros urbanos.

Figura 17: Cidades com Maior Número de Pedidos



4.1.2 ANÁLISE DOS PREÇOS

Os resultados apresentados nas figuras 18, 19 e tabela 20 mostram que a análise das categorias mais vendidas revela que algumas, como "relógios_presentes", possuem preços mais altos, o que indica oportunidades para explorar produtos de maior valor agregado e promover estratégias de vendas focadas em itens premium. Por outro lado, categorias como "telefonica" e "utilidades_domesticas" têm preços médios mais baixos e um número significativo de pedidos, sugerindo que a Olist poderia expandir sua oferta de produtos nessa faixa para atrair consumidores mais sensíveis ao preço. Além disso, a diversidade de preços em categorias como "beleza_saude" e "cama_mesa_banho" apresenta um potencial para segmentar ainda mais o público, oferecendo tanto opções de baixo custo quanto produtos mais caros, o que poderia ser explorado em campanhas de marketing direcionadas para diferentes perfis de clientes.

Figura 18: Distribuição de Preços nas 10 Categorias Mais Vendidas




Figura 19: Distribuição de Preços nas 10 Categorias Mais Vendidas (Abaixo de R\$1.000)





Figura 20: Estatísticas das 10 Categorias Mais Vendidas

product_category_name	num_pedidos	preco_min	preco_max	preco_medio	mediana
cama_mesa_banho	11847	6.99	1999.98	92.49	78.99
beleza_saude	9944	1.2	3124.0	129.82	79.9
esporte_lazer	8942	4.5	4059.0	114.35	76.24
moveis_decoracao	8743	4.9	1899.0	87.54	65.0
informatica_acessorios	8105	3.9	3699.99	116.59	81.5
utilidades_domesticas	7331	3.06	6735.0	90.61	59.54
relógios_presentes	6161	8.99	3999.9	202.2	129.0
telefonica	4692	5.0	2428.0	71.57	29.99
ferramentas_jardim	4558	6.35	3930.0	113.2	59.9
automotivo	4356	3.49	2258.0	139.79	84.72


Os resultados apresentados na Figura 21 indicam variações significativas no preço médio dos produtos entre os estados e regiões do Brasil. Os estados da região Norte, como PB, AC e AL, apresentam preços mais altos, enquanto as regiões Sul e Sudeste têm valores mais baixos, com destaque para SP. Essa distribuição pode sugerir que a Olist explore estratégias de preço diferenciadas, considerando as particularidades de cada região, como custos de distribuição e perfil de consumo.

Figura 21: Estatísticas das 10 Categorias Mais Vendidas



Com base na Figura 22, que mostra os preços médios de frete, é possível observar que os clientes da Região Norte enfrentam custos elevados de frete, além dos preços médios mais altos para os produtos, como foi identificado na análise anterior. Isso sugere que a Olist pode se beneficiar ao revisar suas estratégias logísticas para essa região, como buscar alternativas de transporte mais econômicas ou oferecer promoções para compensar os custos elevados. Além disso, é interessante avaliar a possibilidade de precificação diferenciada e segmentação de produtos, ajustando a oferta para tornar as compras mais acessíveis nesse mercado.


Figura 22: Preço Médio de Frete por Estado e Região do Brasil



4.1.3 ANÁLISE DAS AVALIAÇÕES

Com base na Figura 23, é possível observar que as categorias `cds_dvds_musicais` e `fashion_roupa_infanto_juvenil` possuem as médias de avaliação mais altas, enquanto `seguros_e_servicos` apresenta uma das médias mais baixas. Essa categoria também foi identificada em uma análise anterior como a que tem o menor número de pedidos. Isso sugere que tanto a avaliação negativa quanto a baixa demanda podem estar relacionadas a problemas específicos nessa área. Para a Olist, uma ação importante seria investigar as causas dessas avaliações baixas e o baixo volume de vendas, buscando otimizar a experiência do cliente, melhorar o atendimento ou até mesmo ajustar a oferta de produtos. Além disso, estratégias de marketing para aumentar a visibilidade e a confiança nessa categoria poderiam ajudar a melhorar tanto as avaliações quanto o número de pedidos.

Figura 23: Média de Avaliações por Categoria de Produto



A pontuação média de avaliação dos produtos (representada pelo `review_score`) está diretamente relacionada ao tempo de entrega dos pedidos, refletindo a satisfação do cliente com o processo de compra. Ao analisar o tempo de entrega, calculado como a diferença entre a aprovação do pedido e sua entrega ao cliente (`delivery_time` e `delivery_time_in_hours`), observa-se que uma entrega mais rápida tende a resultar em uma avaliação mais positiva. Isso ocorre porque os consumidores geralmente valorizam a eficiência e a pontualidade nas entregas.

Em diferentes regiões, essa relação pode variar. Regiões com infraestrutura logística mais desenvolvida podem apresentar tempos de entrega mais rápidos, o que, em geral, leva a pontuações de avaliação mais altas. Por outro lado, em áreas com desafios logísticos ou distâncias maiores, o tempo de entrega pode ser mais longo, o que pode influenciar negativamente o `review_score`.

Em resumo, a análise do tempo de entrega e suas variações regionais ajuda a entender como a pontuação das avaliações pode ser impactada. Regiões com entregas rápidas geralmente têm avaliações mais altas, enquanto regiões com entregas mais demoradas podem ver uma queda nas pontuações, evidenciando a importância da eficiência logística para a satisfação do cliente. Essa relação pode ser observada nas figuras 24 e 25.

Figura 24: Relação entre Pontuação Média da Avaliação e Tempo de Entrega por Região






Figura 25: Matriz de Correlação




Os dados mostram que estados com tempos de entrega mais rápidos, como SP e PR, tendem a ter pontuações de avaliação mais altas, enquanto estados com entregas mais lentas, como RR e AM, apresentam pontuações mais baixas. Para melhorar a satisfação do cliente, a empresa pode focar em otimizar a logística nos estados com tempos de entrega mais longos. Essas tendências estão ilustradas na Figura 26.

Figura 26: Relação entre Pontuação Média de Avaliação e Tempo de Entrega por Estado



A distribuição das avaliações dos clientes do e-commerce revela que a maioria das avaliações é positiva, com 65.374 registros de nota 5, seguidos por 21.951 de nota 4. No entanto, também há uma quantidade significativa de avaliações negativas, com 14.546 notas 1 e 4.020 notas 2. Isso pode indicar que, embora a experiência do cliente seja geralmente positiva, há áreas específicas que precisam ser melhoradas. A empresa pode se concentrar em identificar as causas das avaliações mais baixas para aprimorar o atendimento e a qualidade do serviço, buscando uma maior consistência na satisfação dos clientes. O gráfico dessa análise pode ser visualizado na Figura 27.

Figura 27: Distribuição das Avaliações dos Clientes




4.1.4 MÉTRICAS E KPIs

A receita mensal do e-commerce apresenta um crescimento contínuo até agosto de 2018, com valores mais elevados a partir de março de 2017, quando a receita superou os R\$ 400 mil, chegando a valores superiores a R\$ 1 milhão por mês. O pico de receita ocorreu em novembro de 2017, como observamos anteriormente, possivelmente relacionado à Black Friday, que ocorre nesse mês, e como analisado, foi o dia do ano de 2017 com o maior número de vendas.

No ano de 2018, a receita permaneceu estável, com valores acima de R\$ 1 milhão por mês. O crescimento não foi tão expressivo quanto em 2017, mas a empresa manteve um bom desempenho em termos de receita. Essas informações podem ser visualizadas na Figura 28.

Figura 28: Gráfico de Receita Mensal




A variação expressiva na receita no final de 2018 e 2016 levou à análise da quantidade de registros de transações nesses meses. O objetivo foi verificar se a flutuação se deve à falta de dados ou a outros fatores. Foi identificado que, a partir de agosto de 2018 e no final de 2016, houve ausência de registros completos, o que explicou a variação na receita. Essa lacuna será ilustrada na Figura 29.

Figura 29: Contagem de Registros de Transações por Mês

InvoiceYearMonth	Registros
2016-09	3
2016-10	377
2016-12	1
2017-01	998
2017-02	1999
2017-03	3129
2017-04	2760
2017-05	4300
2017-06	3728
2017-07	4773
2017-08	5083
2017-09	5014
2017-10	5491
2017-11	8881
2017-12	6371
2018-01	6304
2018-02	7617
2018-03	8380
2018-04	8123
2018-05	8127
2018-06	7331
2018-07	7242
2018-08	7396
2018-09	1


A análise da Taxa de Crescimento Mensal (MoM), destacada na Figura 30, mostra flutuações significativas no desempenho da empresa, com altas como fevereiro de 2017 (+83,7%) e quedas como dezembro de 2017 (-31,9%). Esses padrões sugerem sazonalidade e possíveis impactos de promoções ou desafios operacionais. Para estabilizar o crescimento, a empresa deve replicar estratégias bem-sucedidas de meses positivos e ajustar campanhas e estoques nos períodos de baixa, garantindo decisões baseadas em dados para um crescimento mais consistente.

Figura 30: Taxa de Crescimento Mensal (MoM)




Entre janeiro de 2017 e agosto de 2018 (Figura 30), o número de Clientes Ativos Mensais (MAU) cresceu 134%, saindo de 735 em janeiro de 2017 para 6.352 em agosto de 2018. O pico em novembro de 2017, com 7.180 clientes, representa um aumento de 63% em relação à média dos três meses anteriores, possivelmente influenciado pela Black Friday, conforme identificado em análises anteriores. Após o pico, houve uma queda de 25% em dezembro, seguida por estabilização em torno de 6.000 clientes mensais. Essa estabilização aponta para a necessidade de estratégias para manter o engajamento pós-eventos sazonais, como campanhas de fidelização e incentivos regulares para estimular compras em períodos mais fracos.

Figura 31: Clientes Ativos Mensais (MAU)



A análise dos pedidos revela crescimento constante, com picos em novembro e dezembro, possivelmente devido à Black Friday. A Olist pode aproveitar esses períodos para lançar campanhas promocionais direcionadas. Por outro lado, o declínio a partir de junho de 2018 indica menor engajamento, sugerindo que a empresa invista em ações como ofertas especiais, lançamento de novos produtos ou campanhas de fidelização para revitalizar o interesse e manter o engajamento dos clientes.


Figura 32: Pedidos Mensais



A análise da Figura 33 destaca que, embora a empresa atraia muitos clientes novos, há uma conversão limitada deles em recorrentes, indicando uma possível alta taxa de churn (desistência). Esse cenário é preocupante, pois o custo de adquirir novos clientes é maior que o de reter os existentes. O comportamento sugere problemas na experiência pós-compra ou na ausência de iniciativas de fidelização.

Os picos de novos clientes em meses como novembro e janeiro mostram que campanhas sazonais são eficazes, mas a falta de retenção limita o crescimento sustentável. Para reverter esse quadro, recomenda-se implementar programas de fidelidade, analisar padrões de churn para ajustar estratégias e monitorar a retenção ao longo do tempo para maximizar o valor de longo prazo dos clientes (LTV).

Figura 33: Variação de Clientes Novos e Existentes por Mês



4.2 ANÁLISE DA SATISFAÇÃO DOS CLIENTES

O código realiza a preparação e limpeza de dados para análise de NLP, focando em comentários de produtos. Primeiramente, seleciona as colunas essenciais: 'review_comment_title', 'review_comment_message' e 'product_category_name', reduzindo o conjunto de dados às informações relevantes. Em seguida, uma função remove duplicatas na coluna de mensagens, mantendo apenas a primeira ocorrência de cada comentário e ajustando os índices.

Posteriormente, aplica-se uma etapa adicional de limpeza, que elimina linhas com valores ausentes em qualquer uma das colunas selecionadas e remove duplicatas restantes na coluna de mensagens. Isso assegura que os dados estejam completos, únicos e consistentes.

O resultado final, armazenado no DataFrame 'df_cleaned', é um conjunto de dados limpo e estruturado, adequado para análises posteriores.

Figura 34: Limpeza e Preparação de Dados para Análise de Sentimentos

```
1 # Selecionando apenas as colunas necessárias para a análise de NLP
2 nlp_df = df[['review_comment_title', 'review_comment_message', 'product_category_name']]
3
4 def remove_duplicates_nlp_df(nlp_df, column_name='review_comment_message'):
5
6     # Remove duplicatas com base na coluna especificada, mantendo a primeira ocorrência
7     nlp_df = nlp_df.drop_duplicates(subset=[column_name], keep='first').reset_index(drop=True)
8
9     # Exibe o total de entradas após remover duplicatas
10    print(f'Total de entradas após remover duplicatas em '{column_name}': {nlp_df.shape[0]}')
11
12    return nlp_df
13
14 # Remove duplicatas do 'nlp_df' com base na coluna 'review_comment_message'
15 nlp_df = remove_duplicates_nlp_df(nlp_df, 'review_comment_message')
16
17 # Exibe os primeiros registros para verificar
18 nlp_df.head()
19
20 def clean_reviews(df):
21
22     # Remove as linhas onde 'review_comment_message' está vazio
23     df = df.dropna(subset=['review_comment_message', 'review_comment_title', 'product_category_name']).reset_index(drop=True)
24
25     # Remove as linhas duplicadas
26     df = df.drop_duplicates(subset=['review_comment_message'])
27
28     return df
29
30 # Supondo que 'nlp_df' seja o seu dataframe
31 df_cleaned = clean_reviews(nlp_df)
32
33 # Exibe os primeiros registros para verificar
34 df_cleaned.head()
```

O código realiza o pré-processamento de comentários textuais em português, preparando os dados para análises de Processamento de Linguagem Natural (NLP). Inicialmente, são definidas as stopwords usando o conjunto padrão da biblioteca NLTK. Em seguida, a função *clean_and_tokenize* é aplicada para normalizar os textos, convertendo-os para letras minúsculas, removendo pontuações e eliminando as palavras de parada. Essa função também divide o texto em tokens, ou seja, em listas de palavras significativas, retornando uma versão limpa do texto e sua lista de tokens. Após isso, a função principal realiza a limpeza do DataFrame, eliminando linhas com valores ausentes nas colunas essenciais, como *review_comment_message* e *review_comment_title*, e removendo duplicatas para evitar redundâncias. Como resultado, o DataFrame processado contém as mensagens originais, suas versões limpas e listas de tokens.

Figura 35: Limpeza e Tokenização de Comentários de Avaliação

```
1 # Define as stopwords em português
2 STOP_WORDS = set(stopwords.words('portuguese'))
3
4 # Função auxiliar para limpar e tokenizar o texto
5 def clean_and_tokenize(text):
6     # Garante que o texto seja uma string
7     if not isinstance(text, str):
8         return "", []
9
10    # Converte para minúsculas, remove pontuação e divide em palavras
11    cleaned_text = text.lower().translate(str.maketrans('', '', string.punctuation))
12    words = cleaned_text.split()
13
14    # Remove as stopwords e cria os tokens
15    filtered_words = [word for word in words if word not in STOP_WORDS]
16    return " ".join(filtered_words), filtered_words
17
18 # Função principal para pré-processar e limpar o dataframe
19 def preprocess_nlp_df(df):
20     # Limpa, remove stopwords e tokeniza os comentários
21     df[['review_comment_message_clean', 'review_comment_message_tokens']] = df['review_comment_message'].apply(
22         lambda text: pd.Series(clean_and_tokenize(text))
23     )
24
25     # Remove as linhas com valores NaN nas colunas-chave
26     df.dropna(subset=['review_comment_title', 'review_comment_message'], inplace=True)
27
28     # Remove as linhas duplicadas com base nas colunas 'review_comment_message' e 'review_comment_title'
29     df.drop_duplicates(subset=['review_comment_message', 'review_comment_title'], inplace=True)
30
31     return df.reset_index(drop=True)
32
33 # Pré-processa o dataset
34 nlp_df = preprocess_nlp_df(nlp_df)
```

O código tem como objetivo realizar a análise de sentimentos sobre os comentários de um DataFrame, especificamente na coluna *review_comment_message_clean*. Para isso, utiliza o *SentimentIntensityAnalyzer*, uma ferramenta da biblioteca VADER, que avalia o sentimento de cada texto com base em uma pontuação. Essa pontuação, denominada *compound*, varia de -1 a 1, e é utilizado para determinar o sentimento do comentário: se o valor for maior ou igual a 0.05, o comentário é classificado como "Positivo"; se for menor ou igual a -0.05, é classificado como "Negativo"; e para valores entre -0.05 e 0.05, o sentimento é considerado "Neutro". A função *classify_sentiment* aplica essa análise a toda a coluna do DataFrame e adiciona os resultados como uma nova coluna, que contém a classificação de sentimento correspondente a cada comentário.

Figura 36: Análise de Sentimentos


```
1 # Inicializa o Analisador de Sentimentos
2 analyzer = SentimentIntensityAnalyzer()
3
4 def classify_sentiment(df, column_name='review_comment_message_clean'):
5     # Função vetorizada para obter a classificação de sentimento
6     def get_sentiment_classification(text):
7         scores = analyzer.polarity_scores(text)
8         if scores['compound'] >= 0.05:
9             return 'Positivo'
10        elif scores['compound'] <= -0.05:
11            return 'Negativo'
12        else:
13            return 'Neutro'
14
15    # Aplica a análise de sentimentos usando map para uma iteração mais rápida
16    df[f'{column_name}_sentiment'] = df[column_name].map(get_sentiment_classification)
17    return df
18
19 # Classifica o sentimento em 'nlp_df' com base na coluna 'review_comment_message_clean'
20 nlp_df = classify_sentiment(nlp_df, 'review_comment_message_clean')
21
22 # Exibe os resultados de sentimento
23 nlp_df[['review_comment_message_clean', 'review_comment_message_clean_sentiment']].head(25)
```

O código gera um gráfico de barras para visualizar a distribuição de sentimentos nas avaliações dos comentários. Ele plota a contagem de cada categoria de sentimento (Positivo, Negativo, Neutro) presente na coluna `review_comment_message_clean_sentiment` do DataFrame. O gráfico é configurado com rótulos para os eixos, um título, e exibe a contagem de cada categoria no topo de suas respectivas barras. Além disso, a visibilidade das linhas de grade é ajustada para um visual mais limpo, com ênfase nas barras. O resultado obtido pode ser visto na Figura 38.

Figura 37: Contagem de Sentimentos nas Avaliações



Figura 38: Visualização de Contagem de Sentimentos



O código realiza a preparação dos dados para treinamento dos modelos de Machine Learning. Ele começa dividindo o conjunto de dados em duas variáveis: X, que contém os comentários das avaliações, e y, que contém os sentimentos correspondentes. Em seguida, os dados são divididos em conjuntos de treinamento e teste, com 20% dos dados reservados para teste. O código também converte as classes categóricas de sentimentos em valores numéricos usando o LabelEncoder, aplicando a codificação nos dados de treinamento e teste. Por fim, é exibido um resumo dos valores únicos no conjunto de treinamento após a codificação, e o LabelEncoder é visualizado.

Figura 39: Pré-processamento e Codificação para Modelagem de Sentimentos

```
1 X = nlp_df['review_comment_message']
2 y = nlp_df['review_comment_message_clean_sentiment']
3
4 # Dividir os dados em treinamento e teste
5 X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)
6
7 # Converter classes categóricas
8 label_encoder = LabelEncoder()
9 y_train_encoded = label_encoder.fit_transform(y_train)
10 y_test_encoded = label_encoder.transform(y_test)
11
12 # Verificar se a conversão foi bem-sucedida
13 print(f"Valores únicos em y_train_encoded após a codificação: {y_train_encoded}")
14
15 # Visualização
16 label_encoder
```

O código, mostrado na figura 40, realiza a vetorização dos textos utilizando a técnica TF-IDF (Term Frequency-Inverse Document Frequency). Primeiramente, é inicializado o TfidfVectorizer, com um limite opcional para o número de características extraídas (5000 neste caso). Em seguida, os textos de treinamento (X_train) são transformados em vetores TF-IDF, e os textos de teste (X_test) são transformados de acordo com o modelo ajustado. Por fim, os vetores são convertidos para arrays densos, o que pode ser necessário para alguns modelos de Machine Learning que não aceitam a forma esparsa dos dados.

Figura 40: Vetorização com TF-IDF

```
1 # Vetorizar o texto usando TF-IDF
2 vectorizer = TfidfVectorizer(max_features=5000) # Limite opcional para o número de características
3
4 # Transformar os textos em vetores TF-IDF
5 X_train_tfidf = vectorizer.fit_transform(X_train)
6 X_test_tfidf = vectorizer.transform(X_test)
7
8 # Converter para arrays densos (se necessário para alguns modelos)
9 X_train_dense = X_train_tfidf.toarray()
10 X_test_dense = X_test_tfidf.toarray()
```

O código inicializa vários modelos de aprendizado de máquina, incluindo DecisionTreeClassifier, RandomForestClassifier, LogisticRegression, KNeighborsClassifier, GradientBoostingClassifier e SVC. Em seguida, para cada modelo, realiza o treinamento com os dados de treinamento (X_train_dense, y_train_encoded) e calcula a acurácia tanto no conjunto de treinamento quanto no de teste. As acurácias de treinamento e teste para cada modelo são armazenadas em uma lista e, ao final, essa lista é convertida em um DataFrame para visualização dos resultados.

Figura 41: Treinamento dos modelos


```

1 # Inicializar os modelos
2 models = {
3     "DecisionTreeClassifier": DecisionTreeClassifier(random_state=42),
4     "RandomForestClassifier": RandomForestClassifier(n_estimators=100, random_state=42),
5     "LogisticRegression": LogisticRegression(random_state=50, max_iter=1000),
6     "KNeighborsClassifier": KNeighborsClassifier(n_neighbors=5, metric='minkowski', p=2),
7     "GradientBoostingClassifier": GradientBoostingClassifier(random_state=42),
8     "SVC": SVC(kernel='linear', random_state=42, probability=True)
9 }
10
11 # Treinar os modelos e calcular as pontuações de acurácia
12 results = []
13 for name, model in models.items():
14     model.fit(X_train_dense, y_train_encoded)
15     train_accuracy = accuracy_score(y_train_encoded, model.predict(X_train_dense))
16     test_accuracy = accuracy_score(y_test_encoded, model.predict(X_test_encoded))
17     results.append(("Modelo": name, "Acurácia de Treinamento": train_accuracy, "Acurácia de Teste": test_accuracy))
18
19 pd.DataFrame(results)

```


O código gera gráficos da matriz de confusão para cada modelo treinado. Para cada modelo, ele faz previsões usando os dados de teste e calcula a matriz de confusão. Em seguida, plota a matriz de confusão utilizando um gráfico de calor (heatmap) com as classes previstas e verdadeiras, mostrando a quantidade de previsões corretas e incorretas. Cada gráfico é rotulado com o nome do modelo correspondente, como pode ser observado na figura 42.

Figura 42: Matriz de confusão



O código gera curvas ROC para cada modelo treinado. Primeiramente, os rótulos de teste são binarizados, e o número de classes é determinado. Em seguida, para cada modelo, são feitas previsões de probabilidade (ou função de decisão, se o modelo não tiver a função `predict_proba`). Para cada classe, são calculados os valores de FPR (taxa de falso positivo) e TPR (taxa de verdadeiro positivo), a partir dos quais a AUC (Área Sob a Curva) é calculada e plotada. O gráfico de cada modelo é exibido com a curva ROC, e a legenda mostra o valor da AUC para cada classe. As curvas ROC de cada modelo serão exibidas na Figura 44.

Figura 44: Curvas ROC de Desempenho dos Modelos



Em seguida, foi gerado o relatório de classificação para cada modelo, avaliando as métricas de precision, recall, F1-score e acurácia para cada classe de sentimento. Através das avaliações, foi observado que o melhor modelo foi o SVC. Esse resultado pode ser observado na Figura 45. Dado o seu desempenho superior, o modelo SVC será o escolhido para o deploy no Streamlit.

Figura 45: Avaliação dos modelos treinados

Classification Report - KNeighborsClassifier					Classification Report - LogisticRegression				
	precision	recall	f1-score	support		precision	recall	f1-score	support
Negativo	0.92	0.11	0.19	216	Negativo	0.88	0.65	0.75	216
Neutro	0.36	0.93	0.52	486	Neutro	0.81	0.88	0.84	486
Positivo	0.92	0.41	0.57	1021	Positivo	0.92	0.94	0.93	1021
accuracy			0.52	1723	accuracy			0.88	1723
macro avg	0.74	0.48	0.43	1723	macro avg	0.87	0.82	0.84	1723
weighted avg	0.77	0.52	0.51	1723	weighted avg	0.89	0.88	0.88	1723
Classification Report - DecisionTreeClassifier					Classification Report - RandomForestClassifier				
	precision	recall	f1-score	support		precision	recall	f1-score	support
Negativo	0.66	0.52	0.58	216	Negativo	0.92	0.48	0.63	216
Neutro	0.76	0.94	0.88	486	Neutro	0.76	0.85	0.80	486
Positivo	0.89	0.88	0.89	1021	Positivo	0.89	0.93	0.91	1021
accuracy			0.83	1723	accuracy			0.85	1723
macro avg	0.77	0.75	0.75	1723	macro avg	0.86	0.75	0.78	1723
weighted avg	0.82	0.83	0.82	1723	weighted avg	0.86	0.85	0.84	1723
Classification Report - GradientBoostingClassifier					Classification Report - SVC				
	precision	recall	f1-score	support		precision	recall	f1-score	support
Negativo	0.98	0.60	0.72	216	Negativo	0.85	0.73	0.79	216
Neutro	0.75	0.90	0.81	486	Neutro	0.84	0.92	0.88	486
Positivo	0.92	0.90	0.91	1021	Positivo	0.95	0.94	0.94	1021
accuracy			0.86	1723	accuracy			0.91	1723
macro avg	0.86	0.80	0.82	1723	macro avg	0.88	0.86	0.87	1723
weighted avg	0.87	0.86	0.86	1723	weighted avg	0.91	0.91	0.91	1723

5 CONCLUSÃO

O presente trabalho demonstrou como a análise exploratória de dados e técnicas de Machine Learning podem ser integradas para fornecer insights estratégicos e soluções preditivas no contexto do e-commerce. Com base nos dados disponibilizados pela Olist, foi possível identificar padrões de comportamento dos consumidores, tendências regionais e métricas de desempenho que impactam diretamente a satisfação do cliente.

Os resultados alcançados evidenciam a relevância de compreender fatores como tempo de entrega, custo de frete, categoria de produto e tipo de pagamento, que exercem influência significativa na percepção do consumidor sobre a qualidade do serviço. A análise exploratória destacou variações sazonais nas vendas e métricas de crescimento, como a taxa de crescimento mensal e o número de clientes ativos, fornecendo direcionamentos para a otimização de estratégias comerciais.

Além disso, o modelo preditivo desenvolvido neste estudo, apoiado por técnicas como vetorização de texto e algoritmos supervisionados, apresentou potencial para classificar e prever sentimentos nas avaliações dos clientes. Isso possibilita à empresa não apenas antecipar problemas, mas também agir proativamente para melhorar a experiência do consumidor.

O deploy do modelo por meio do Streamlit consolidou o trabalho ao criar uma interface interativa e acessível, facilitando o uso dos insights e previsões pelos usuários finais. Essa abordagem prática reforça a aplicabilidade dos resultados no ambiente empresarial, permitindo decisões mais informadas e estratégias personalizadas.

Em síntese, este trabalho contribui para a compreensão dos desafios e oportunidades no uso de dados no e-commerce, oferecendo uma solução prática e escalável para empresas que buscam melhorar a experiência do cliente e alcançar um desempenho competitivo. Como futuras linhas de pesquisa, recomenda-se explorar técnicas avançadas de deep learning e integrar fontes de dados externas para uma visão ainda mais abrangente.

REFERÊNCIAS